

11.5. Nota Técnica: Integración de Datos Públicos para Análisis Territorial

DataJam Edición 4 – Universidad Distrital Francisco José de Caldas

Agosto 2026

Resumen

Esta nota técnica detalla la experiencia de integración de fuentes de datos públicos empleadas en el análisis de la relación entre deserción escolar y vulnerabilidad socioeconómica en Bogotá. El documento evalúa la disponibilidad, las complejidades de unificación y la interoperabilidad de los datos, aportando recomendaciones de carácter metodológico.

1 Disponibilidad y Actualización de los Datos

El análisis consolida información geoespacial, de encuestas y de registros administrativos recolectada entre 2021 y 2025. La procedencia y el estado de las fuentes son los siguientes:

- **Portal de Datos Abiertos de Bogotá:** Fuente principal de la cual se obtuvieron los datasets de *Pobreza y Desigualdad (2011-2025)*, *Tasas de Deserción por UPL (2024)*, *Vulnerabilidad Calidad del Agua*, *Violencia Intrafamiliar* y la *Matrícula en Jornada Única (2025)*. Presentan una disponibilidad continua a través de descargas directas HTTP, facilitando la automatización del flujo.
- **Secretaría Distrital de Planeación (SDP):** De su sitio web institucional se obtuvo la *Encuesta Distrital de Percepción Ciudadana 2025* y la *Encuesta Multipropósito 2021* (esta última en coautoría con el DANE). Estos insumos proveen una riqueza subjetiva y de microdatos de alta calidad, aunque no están centralizados en el portal único de datos abiertos.

2 Complejidad Técnica en la Integración

La unificación de las fuentes presentó desafíos técnicos significativos asociados a la heterogeneidad de los datos:

1. **Desalineación Geográfica:** La deserción escolar y la percepción se reportan a nivel de Unidades de Planeamiento Local (UPL), mientras que la pobreza y la matrícula oficial se estructuran por Localidades. Para posibilitar el cruce de variables, se implementó un mapeo estático explícito de códigos UPL a Localidades.
2. **Formatos y Estructuras:** Se integraron archivos en formato plano (CSV) con archivos vectoriales (GeoJSON). Los archivos CSV exhibieron inconsistencias de codificación (requiriendo decodificación en `latin-1`) y delimitadores mixtos, además de representar números decimales con comas en lugar de puntos (ej. `osb_demografia-pobrezaygini.csv`).
3. **Volumen de Información:** El procesamiento de microdatos a nivel de registro (como la Encuesta Multipropósito con ~500 MB y Violencia Intrafamiliar con ~110 MB) exigió optimizaciones de carga (`low_memory=False` en pandas) para prevenir desbordamientos de memoria en la ejecución del análisis.

3 Interoperabilidad y Estructura

Se evidenció una falta de normalización en las propiedades geoespaciales de los GeoJSON. Los nombres de las claves de atributos varían aleatoriamente entre mayúsculas y minúsculas (`CODIGO_UPL`, `codigo_upl`, `COD_LOCA`, `cod_loca`), lo cual obstaculiza la validación automatizada de esquemas. Asimismo, la ausencia de identificadores catastrales comunes en las encuestas dificulta el análisis a escalas de mayor resolución (como barrios o UPZ).

4 Recomendaciones para el Análisis Territorial

Para fortalecer el aprovechamiento de datos públicos, se proponen las siguientes mejoras metodológicas:

- **Estandarización Geoespacial:** Definir un estándar unificado para nombres de variables y claves geográficas en los portales públicos de la administración distrital.
- **APIs de Acceso Directo:** Implementar puntos de enlace (endpoints) de consultas filtradas en lugar de descargas masivas de archivos planos gigantescos, optimizando el ancho de banda y la velocidad de ejecución.
- **Homogeneización Numérica:** Asegurar que todos los datasets utilicen el estándar de punto decimal e ISO-8859-1 o UTF-8 de forma uniforme en la codificación de caracteres.